

Fundamentos Estadísticos para Inteligencia Artificial

Curso inicial: De la naturaleza de los datos al entrenamiento de modelos robustos.

Biblioteca del Congreso Nacional de Chile

Módulo 1: Limpieza y Preparación

¿Por qué la estadística define el éxito?

La IA no es magia, es **cálculo probabilístico**. Antes de programar, debemos entender el comportamiento matemático de nuestra información.

- **Garbage In, Garbage Out:** Si la estadística base está mal, el modelo más avanzado fallará.
- **Generalización:** Buscamos que el modelo aprenda reglas universales, no anécdotas del dataset.
- **Estabilidad:** La varianza determina qué tan confiable será la predicción mañana.



Estructura > Algoritmo

El 80% del trabajo de un Científico de Datos es limpiar y estructurar datos.

4.

1. La Materia Prima: Tipos de Datos

Identificar el tipo de dato es el primer paso, ya que cada uno requiere un tratamiento matemático distinto.



Numérico Continuo

Valores infinitos en un rango
(Ej: Temperatura, Precio).

Requiere: Escalamiento



Numérico Discreto

Conteos enteros (Ej: N° de hijos, visitas web).

Requiere: Normalización



Categorico Nominal

Etiquetas sin orden (Ej: Colores, Países, Género).

Requiere: One-Hot Encoding



Categorico Ordinal

Etiquetas con jerarquía (Ej: Bajo, Medio, Alto).





Requiere: Label Encoding

2. Verificación Visual: No confíes ciegamente

El Cuarteto de Anscombe

Cuatro datasets pueden tener exactamente la misma media y varianza, pero ser visualmente opuestos.

- La estadística descriptiva (μ , σ) resume, pero también oculta.
- Siempre grafica tus datos (Histogramas, Scatter Plots) antes de entrenar.
- **Riesgo:** Un modelo puede intentar trazar una línea recta en datos que visualmente son una parábola.



3. Tendencia Central: ¿Dónde está el centro?


Media vs. Mediana

En una distribución perfecta (curva normal), coinciden. Pero en datos reales (asimetría), se separan peligrosamente.


Regla de decisión:

- **Simétrica:** Usa la Media (μ).
- **Sesgada (Skewed):** Usa la Mediana. Es más robusta a outliers.

Uso en IA: Si imputas nulos con la media en datos sesgados, corrompes el dataset.



Left-Skewed (Negative Skewness)



Right-Skewed (Positive Skewness)

4. Dispersión: Varianza y Desviación


Saber el centro es inútil si no sabemos cuánto varían los datos.

Varianza (σ^2)

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{N}$$

Desviación Estándar (σ): Raíz de la varianza. Nos dice el rango "normal" de los datos.

Impacto en IA: Una varianza alta implica mayor dificultad para predecir.





5. El Impacto de los "Datos Raros" (Outliers)

En modelos basados en error (Redes Neuronales, Regresión), el error de un outlier se **eleva al cuadrado**.

Esto genera **gradientes explosivos**: el modelo intenta desesperadamente corregir ese error único, destruyendo su capacidad de predecir los datos normales.

Efecto Palanca:

Un solo dato erróneo puede mover una recta de regresión 30 grados.



Estrategias para Outliers



Trimming (Cortar)

Eliminar si es un error obvio (ej: Edad = 200). Usar con cuidado en datasets pequeños.

Criterio: > 3 desviaciones estándar.



Capping (Winsorización)

No eliminar, sino "topearlos". Si valor $> P99$, asignar valor del P99.

Evita perder información válida.



Log Transform

Aplicar $\log(x)$ comprime los valores altos.

Ideal para salarios o precios de casas.


6. Temporalidad: El sesgo silencioso

¿Analizar un año con datos de dos meses?

¡ERROR GRAVE!

Los modelos de IA asumen que los datos de entrenamiento son representativos del futuro. Debes detectar **Estacionalidad** y **Tendencias**.

- **Estacionalidad:** Patrones que se repiten (ventas en Navidad, tráfico en hora punta).
- **Data Leakage:** Nunca uses datos del futuro para predecir el pasado durante el entrenamiento.



7. Datos Faltantes (NaN): ¿Qué hacemos?

Acción	Caso de Uso	Consecuencia Matemática
Imputar Media	Distribución normal.	Reduce la varianza. Puede sesgar hacia el centro.
Imputar Mediana	Datos con Outliers.	Más seguro y robusto. No altera tanto la distribución.
Rellenar con 0	Ausencia real (ej: sin deuda).	Correcto si tiene sentido físico. Peligroso si no (Edad=0).
Eliminar	Filas con >50% nulos.	Pérdida de información. Solo si sobran datos.


8. Escalamiento: Igualdad de condiciones

Si una variable es "Salario" (millones) y otra "Edad" (decenas), la IA ignorará la edad por ser numéricamente pequeña.

Z-Score (StandardScaler):

$$Z = \frac{x - \mu}{\sigma}$$

El gráfico muestra cómo el escalamiento centra los datos en (0,0) sin deformar su patrón.





9. El Resultado Final: Sesgo vs. Varianza

El Equilibrio Perfecto

- **Sesgo Alto (Underfitting):**
El modelo es muy simple (línea recta en datos curvos). No aprende ni la señal ni el ruido.
- **Varianza Alta (Overfitting):**
El modelo es muy complejo. Memoriza el dataset de entrenamiento y falla en producción.

Buscamos el punto medio (Generalización).



Resumen: Pipeline de Preparación

1. Visualizar

Histogramas y Scatter plots para ver la forma real.

2. Limpiar

Tratar Outliers (Capping) e imputar NaNs (Mediana).

3. Transformar

Encoding categórico y escalamiento numérico.

4. Verificar

Revisar balance de clases y temporalidad.

¿Preguntas?

Estadística Aplicada a Ciencia de Datos

Biblioteca del Congreso Nacional de Chile