



Arcadia
ingeniería



Machine Learning Supervisado

Cómo los modelos aprenden a clasificar
documentos, usuarios o eventos

Sesión 3 - Felipe Carrasco



El modelo aprende con ejemplos

Funcionamiento

- Tenemos X (características) y Y (etiquetas).
- El modelo “ve” muchos ejemplos y aprende patrones.
- La meta: predecir correctamente la etiqueta de nuevos datos.

Dado un documento parlamentario → ¿es urgente o no urgente?



Donde se usa en sisred



Clasificacion

Clasificar de documentos de forma automática.



Deteccion

Detectar usuarios con patrones inusuales o eventos relevantes en textos.




Priorizar

Priorización de solicitudes según importancia.

Clasificación = tomar decisiones automáticas.

El flujo real de un proyecto ML

El éxito depende más del pipeline que del modelo.



Preprocesamiento

01

- Eliminar duplicados
- Manejar valores faltantes
- Detectar y tratar outliers
- Normalizar o estandarizar

02

Un modelo con datos sucios = un modelo malo.



Feature Engineering

Cómo crear características útiles de verdad



Extraer longitud,
frecuencia,
rareza



Contar palabras
clave



Transformaciones
simples →
enormes mejoras




Cantidad de veces que
aparece 'urgente' en el
documento




Entrenamiento + Validación

¿Cómo sabemos si el modelo funciona?




Proceso

- Dividir datos en train / test
- Validación cruzada para evitar suerte
- Evaluar con métricas correctas (accuracy, precision, recall, F1)




Entrenamiento + Validación

¿Cómo sabemos si el modelo funciona?



Proceso

- Dividir datos en train / test
- Validación cruzada para evitar suerte
- Evaluar con métricas correctas (accuracy, precision, recall, F1)



Modelos que funcionan muy bien para SISRED



Tendencias del Mercado

Logistic Regression

Lógica del modelo:
Aprende una línea recta que separa dos clases.

Útil para:

- Datos numéricos o estructurados
- Sistemas donde la interpretabilidad importa

01

Decision Tree

Lógica del modelo:
Toma decisiones mediante preguntas sí/no

Útil para:

- Datos mixtos (texto + categorías + números)
- Modelos explicables

02

Random Forest

Lógica del modelo:
Construye muchos árboles y votan entre sí.

Cada árbol mira una parte distinta de los datos.

Útil para:

- Máxima precisión sin sobre ajuste

03

Listos para Clasificar SISRED

Con esto ya tenemos todo lo necesario para construir el primer clasificador real para SISRED. Aprenderemos el flujo completo: cómo preparar datos, cómo elegir modelos y cómo evaluar si realmente funcionan.



Modelo de Clasificación

Tecnología