

SEMINARIO DE MACHINE LEARNING

Representación de Texto para Clasificación

Bag-of-Words, TF-IDF y Embeddings Vectoriales

Análisis de técnicas para la transformación de datos no estructurados en vectores numéricos.

El Desafío de los Datos No Estructurados

De Texto a Números

A diferencia de los datos tabulares tradicionales, el texto es información **no estructurada**. Para que los algoritmos de Machine Learning puedan procesarlo, es imperativo convertirlo en **feature vectors** (vectores numéricos).

Exploraremos tres enfoques de complejidad creciente:

- **Bag-of-Words (BoW):** Frecuencia simple.
- **TF-IDF:** Frecuencia ponderada.
- **Embeddings:** Representación semántica densa.




1. Bolsa de Palabras (Bag-of-Words)

Concepto Fundamental

BoW es la técnica más básica que representa un documento mediante la **frecuencia de ocurrencia** de sus palabras, ignorando completamente la estructura gramatical y el orden.

"Es como un histograma de palabras: solo importa qué palabras hay y cuántas veces aparecen."

Cada dimensión del vector corresponde a una palabra única del vocabulario global (ej. 10,000 dimensiones).



Ejemplo de Representación BoW

Observe cómo se pierde el orden: frases con significados opuestos pueden tener representaciones idénticas.

Documento	el	perro	gato	muerde	al	Vector Resultante
"El perro muerde al gato"	1	1	1	1	1	[1,1,1,1,1]
"El gato muerde al perro"	1	1	1	1	1	[1,1,1,1,1]

i Nota: Esta incapacidad para distinguir sintaxis es la limitación estructural más grande de BoW.

Análisis Crítico: Bag-of-Words

Fortalezas

- **Simplicidad y Velocidad:** Cálculo determinista extremadamente rápido.
- **Interpretabilidad:** Cada dimensión es una palabra clara. Si "oferta" tiene valor alto, el texto trata sobre ofertas.
- **Eficacia Probada:** Funciona sorprendentemente bien en tareas donde la presencia de palabras clave es suficiente (ej. Spam vs Ham, Clasificación de Política).

Limitaciones

- **Sparsity (Dispersión):** Vectores gigantes con mayoría de ceros, ineficiente en memoria.
- **Pérdida de Contexto:** No distingue "No aprobar" de "Aprobar no".
- **Independencia:** "Automóvil" y "Coche" son dimensiones separadas sin relación matemática entre ellas.


2. TF-IDF (Term Frequency - Inverse Document Frequency)

Refinando la Frecuencia

TF-IDF es una evolución de BoW que **reasigna pesos** a las palabras basándose en su singularidad en todo el corpus.

La intuición es simple:

- Si una palabra aparece en *todos* los documentos (ej. "el", "que"), es poco informativa -> **Bajo peso**.
- Si una palabra aparece mucho en *un* documento pero raramente en otros -> **Alto peso** (altamente discriminativa).



Formulación Matemática

$$\text{TF-IDF} = \text{TF} \times \text{IDF}$$

Term Frequency (TF)

Frecuencia de la palabra en el documento actual.
Mide la relevancia local.

Inverse Document Frequency (IDF)

$$\log \frac{\text{\#Docs Totales}}{\text{\#Docs con la palabra}}$$

Penaliza palabras que aparecen en todas partes (log de 1 es 0).

Ejemplo Práctico: Noticias

Supongamos un corpus de 1000 noticias. Comparamos los términos "Gobierno" (común) vs "Inflación" (específico) en un documento donde ambos aparecen 5 veces.

Término	Frecuencia Local (TF)	Aparición Global (Docs)	Cálculo IDF	Peso TF-IDF
"Gobierno"	5	300 (Común)	$\log(1000/300) \approx 0.52$	$5 \times 0.52 = \mathbf{2.6}$
"Inflación"	5	50 (Raro)	$\log(1000/50) \approx 2.30$	$5 \times 2.30 = \mathbf{11.5}$

Conclusión: Aunque ambas palabras aparecen 5 veces, "Inflación" pesa 4 veces más, caracterizando mejor el tema del documento.

Análisis Crítico: TF-IDF



Reducción de Ruido

Su mayor ventaja es atenuar el impacto de palabras comunes sin contenido semántico (stopwords) sin necesidad de eliminarlas manualmente. Ideal para documentos técnicos.



Estándar Industrial

Ha sido el "baseline" dorado durante décadas. Combinado con regresión logística, ofrece resultados competitivos y robustos con muy bajo costo computacional.



Limitaciones Persistentes


Hereda los problemas de BoW: alta dimensionalidad y, crucialmente, **falta de semántica**. No entiende que "coche" y "auto" son lo mismo.

3. Embeddings Vectoriales

Representación Semántica Densa

Los embeddings (incrustaciones) rompen el paradigma de BoW. En lugar de vectores dispersos de 10,000 dimensiones, usamos vectores **densos** de baja dimensión (ej. 300).

Se entrenan mediante redes neuronales en grandes corpus (Wikipedia, Common Crawl) para que palabras con significados similares estén **geométricamente cerca** en el espacio vectorial.



Mecánica de los Embeddings


Aprendizaje por Contexto

Modelos como **Word2Vec** o **GloVe** aprenden intentando predecir una palabra dado su contexto (o viceversa). Como resultado, capturan relaciones analógicas.

Aritmética Vectorial Famosa:

$$\text{Vec}(\text{"Rey"}) - \text{Vec}(\text{"Hombre"}) + \text{Vec}(\text{"Mujer"}) \approx \text{Vec}(\text{"Reina"})$$

Esto permite al modelo "entender" género, tiempos verbales y sinónimos sin reglas explícitas.



Análisis Crítico: Embeddings

Poder Semántico

- **Generalización:** Si el modelo aprende sobre "automóviles", reconocerá un documento sobre "coches" aunque nunca haya visto esa palabra en el entrenamiento, gracias a la cercanía vectorial.
- **Dimensionalidad Reducida:** Vectores de tamaño 300 vs 100,000. Menor riesgo de overfitting en modelos complejos.
- **Transfer Learning:** Podemos usar embeddings pre-entrenados por Google o Facebook.

El Problema de la "Caja Negra"

- **Interpretabilidad Nula:** Las dimensiones son latentes. No podemos mirar el vector y decir "la dimensión 5 es política".
- **Polisemia (Word2Vec):** Modelos simples asignan un solo vector a "Banco" (asiento y dinero), promediando significados. (Modelos como BERT solucionan esto pero son más costosos).

Resumen Comparativo

Característica	Bag-of-Words (BoW)	TF-IDF	Embeddings (Word2Vec)
Dimensionalidad	Alta (Dispersa)	Alta (Dispersa)	Baja (Densa)
Semántica	Nula (Independencia)	Nula	Alta (Similitud)
Interpretabilidad	Alta	Alta	Baja (Caja Negra)
Caso de Uso Ideal	Filtros simples, Keywords	Clasificación Temática	NLP Complejo, Generalización


"Comience con TF-IDF por su robustez; escale a Embeddings si necesita comprensión semántica profunda."

Image Sources



https://img.freepik.com/premium-vector/blue-stream-binary-code-digital-flow-encoded-data-analysis-blockchain-transfer-big-data-visualization-vector-matrix-background-coding-hacking_698341-532.jpg

Source: www.freepik.com




https://miro.medium.com/1*axffCQ9aeOFHXxhuy66FbA.png

Source: ayselaydin.medium.com




https://media.istockphoto.com/id/925167552/photo/math-physics-formulas.jpg?s=612x612&w=0&k=20&c=clq1FKHZwp_1H7AHFyDPbFpgOQh7dytQCQMqnExOPCo=

Source: www.istockphoto.com



<https://www.sthda.com/sthda/RDoc/figure/3d-graphics/scatterplot3d-scatter-plot-3d-color-by-groups-r-data-visualization-1.png>

Source: www.sthda.com



<https://informatics.ed.ac.uk/sites/default/files/thumbnails/image/diagram-20190710.png>

Source: informatics.ed.ac.uk
