



BIBLIOTECA DEL CONGRESO NACIONAL DE CHILE

Visión Artificial

"De píxeles a decisiones: Aprendiendo representaciones"

Introducción a Redes Neuronales y Deep Learning para el Sector Público


¿Qué ve realmente un computador?

La Matriz Numérica


Para nosotros es una imagen; para la IA es un **tensor**. Una imagen se representa como una matriz tridimensional de números.

Dimensiones = $H \times W \times C$

- **H (Height):** Altura en píxeles.
- **W (Width):** Ancho en píxeles.
- **C (Channels):** Canales de color (RGB = 3).
- Los valores van de 0 a 255 (intensidad), pero los normalizamos a $[0, 1]$ para facilitar el aprendizaje.



Fundamentos: El Perceptrón Multicapa



Arquitectura Básica

Las redes neuronales (Deep Learning) se inspiran vagamente en el cerebro biológico.

- **Neuronas:** Unidades de cómputo que realizan una suma ponderada de entradas.
- **No-linealidad (ReLU):** Esencial para aprender patrones complejos. Sin ella, la red sería solo una regresión lineal gigante.

- $$\text{ReLU}(x) = \max(0, x)$$

- Las capas profundas permiten abstraer información: de bordes simples a conceptos abstractos.

El Problema de las Redes Tradicionales (MLP)



Explosión de Parámetros

En un MLP, cada píxel se conecta a cada neurona. Para una imagen de 1000x1000, ¡son millones de conexiones! Esto es ineficiente y lento.



Pérdida Espacial

Al "aplanar" la imagen en un vector, el MLP pierde la noción de vecindad. No sabe qué píxel está al lado de cuál, perdiendo patrones visuales.



Falta de Invariancia


Si un objeto se mueve de la izquierda a la derecha, un MLP tiene que "volver a aprenderlo". Las CNNs detectan el patrón sin importar dónde esté.

La Solución: Redes Convolucionales (CNN)

Filtros y Mapas de Características

En lugar de conectar todo con todo, usamos **filtros (kernels)** pequeños que escanean la imagen.

- **Conectividad Local:** La red analiza pequeñas regiones vecinas.
- **Pesos Compartidos:** El mismo filtro busca el mismo patrón (ej. un borde vertical) en toda la imagen.
- **Feature Maps:** El resultado es un mapa que indica "dónde" se encontró cierta característica visual.



La Solución: Redes Convolucionales (CNN)

¹ 3	⁰ 0	⁻¹ 1	2	7	4
¹ 1	⁰ 5	⁻¹ 8	9	3	1
¹ 2	⁰ 7	⁻¹ 2	5	1	3
0	1	3	1	7	8
4	2	1	6	2	8
2	4	5	2	3	9

Imagen: 6x6

*

1	0	-1
1	0	-1
1	0	-1

Filtro (kernel): 3x3

=

-5			

Resultado: 4x4

La Solución: Redes Convolucionales (CNN)

0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

Kernel

0	-1	0
-1	5	-1
0	-1	0

114				

Jerarquía y Reducción: Pooling

Max Pooling

29	15	28	184
0	100	70	38
12	12	7	2
12	12	45	6

2 x 2
pool size

100	184
12	45

Average Pooling

31	15	28	184
0	100	70	38
12	12	7	2
12	12	45	6

2 x 2
pool size


36	80
12	15

Max Pooling

Para procesar información a gran escala, necesitamos reducir la dimensionalidad progresivamente.

- **Submuestreo:** Nos quedamos solo con el valor más alto de cada región (ej. 2x2).
- **Efecto:** Reduce el tamaño de la imagen pero conserva la característica más importante detectada.
- **Resultado:** Permite que las capas siguientes vean un panorama más amplio ("el bosque en vez del árbol").

La Solución: Redes Convolucionales (CNN)



¿Cómo aprende la red?



1. Forward Pass

La imagen pasa por la red. Al principio, con pesos aleatorios, la predicción será "basura" (aleatoria).



2. Loss & Backprop

Calculamos el error (Loss Function) comparando con la etiqueta real. El error se propaga hacia atrás para culpar a los pesos responsables.



3. Optimización

Usamos algoritmos como *Adam* o *SGD* para ajustar ligeramente los pesos y reducir el error. Repetimos esto miles de veces (Épocas).

Generalización y Sobreajuste

El Riesgo de Memorizar

Si la red solo memoriza los ejemplos de entrenamiento, fallará en el mundo real (Sobreajuste/Overfitting).

- **Validación:** Siempre separamos datos que la red NUNCA ve durante el entrenamiento para evaluarla honestamente.
- **Data Augmentation:** Creamos variaciones sintéticas (rotar, zoom, ruido) de las imágenes para obligar a la red a aprender conceptos robustos, no píxeles exactos.




Rotación, Escalado, Ruido


Tareas Principales de Visión




Image Recognition



Semantic Segmentation



Object Detection



Instance Segmentation


- **Clasificación:** "¿Qué es esto?"
Asigna una etiqueta global a la imagen (ej. "Gato").
- **Detección de Objetos:** "¿Qué hay y dónde?"
Localiza objetos con cajas delimitadoras (Bounding Boxes).
- **Segmentación:** "Píxel a píxel"
Clasifica cada píxel individualmente para obtener la forma exacta (Máscaras).

Interpretabilidad: La "Caja Negra"

¿En qué se fija la red?

A menudo se dice que las IAs son cajas negras, pero en visión tenemos herramientas para entenderlas.

- **Mapas de Saliencia & Grad-CAM:** Técnicas que generan un mapa de calor sobre la imagen original.
- **Interpretación:** Las zonas rojas/cálidas indican los píxeles que más influyeron en la decisión final.
- Esto es crucial para auditar modelos en el sector público y evitar sesgos.



Aplicaciones en la BCN

Digitalización Inteligente

Clasificación de Documentos: Separar automáticamente portadas, índices, boletines y tablas en archivos históricos masivos.

Control de Calidad OCR: Detectar automáticamente escaneos borrosos o defectuosos antes de enviarlos a reconocimiento de texto, ahorrando tiempo de cómputo.

Detección de Firmas: Localizar firmas manuscritas en actas legislativas antiguas.

SCANNING OPS



Brewster Kahle we are on!
Louis Brizuela :chillwcat:

AT'S
?

¿Preguntas?

"Pasamos de píxeles a decisiones,
aprendiendo representaciones."



Gracias por su atención