

# Arquitecturas RAG:

Transformando LLMs genéricos en  
herramientas institucionales confiables

Curso de IA para SISRED - BCN

Felipe Fuentes Villegas - Arcadia Ingeniería





# Limitaciones de LLMs

- **Conocimiento congelado:** datos entrenados hasta una fecha delimitada.
- **Alucinaciones:** tendencia a inventar hechos y respuestas con tal de complacer al usuario.
- **Caja negra:** falta de trazabilidad en las fuentes.
- **Privacidad:** imposibilidad de usar datos sensibles en modelos públicos.



# ¿Qué es RAG?


## IA con biblioteca externa

RAG, o **Retrieval-Augmented Generation**, es una arquitectura innovadora que permite a la inteligencia artificial acceder a información externa en tiempo real (actualizable), mejorando la precisión y relevancia de las respuestas.

¿Cuál es el campeón del fútbol chileno?



Usuario



LLM

## Desafíos de LLM's

1. Fuente de información
2. Información obsoleta

# ¿Qué es RAG?

## IA con biblioteca externa

RAG, o **Retrieval-Augmented Generation**, es una arquitectura innovadora que permite a la inteligencia artificial acceder a información externa en tiempo real (actualizable), mejorando la precisión y relevancia de las respuestas.




## Desafíos de LLM's

1. Fuente de información
2. Información obsoleta

# ¿Qué es RAG?

## IA con biblioteca externa

RAG, o **Retrieval-Augmented Generation**, es una arquitectura innovadora que permite a la inteligencia artificial acceder a información externa en tiempo real (actualizable), mejorando la precisión y relevancia de las respuestas.



## Desafíos de LLM's

1. Fuente de información
2. Información obsoleta


# ¿Qué es RAG?

## IA con biblioteca externa

RAG, o **Retrieval-Augmented Generation**, es una arquitectura innovadora que permite a la inteligencia artificial acceder a información externa en tiempo real (actualizable), mejorando la precisión y relevancia de las respuestas.

## Desafíos de LLM's

1. Fuente de información
2. Información obsoleta






# Documentos y ETL

La calidad documental es crucial para obtener buenas respuestas en IA, no basta con subir solamente el PDF.

- Limpieza de documentos
- Transformación de datos
- **Chunking** para preservar contexto






# Embeddings en Arquitecturas RAG


## Representación vectorial eficaz

Los **embeddings** son vectores numéricos que representan texto, permitiendo **búsquedas semánticas** avanzadas y mejorando la precisión de la recuperación de información.





# Almacenamiento Eficiente de Vectores




## BBDD Moderna

El **Vector Store** permite almacenar millones de vectores de manera eficiente, facilitando la búsqueda por similitud y mejorando la rapidez de la recuperación de información relevante.

# Recuperación y Generación

1º parte del flujo



## Algoritmo y LLM

El **algoritmo recuperador** selecciona fragmentos relevantes del almacenamiento vectorial, mientras que el LLM generador construye respuestas naturales usando esos fragmentos (contexto) y la pregunta del usuario.

# Ingesta de Datos

## 2da parte del flujo

### Proceso de preparación esencial para la arquitectura RAG y su eficiencia

- Documentos de origen
- Limpieza y organización
- Generación de embeddings
- Almacenamiento en Vector Store





# Ventajas de usar RAG

- La arquitectura RAG permite que cada afirmación de IA cite el documento original, garantizando así la **transparencia** y confianza en las respuestas generadas por el sistema.
- Sabe decir que no sabe.
- Permite la actualización de documentos y contexto de manera ágil, eliminando la necesidad de reentrenar el modelo, lo que reduce altísimos costos y aumenta la adaptabilidad institucional.

## Key Advantages of RAG

